ГОДОВОЙ ПРОЕКТ · ЧЕКПОЙНТ 2 · EDA

Оценка товара по тексту отзыва

Многоклассовая классификация 1–5 на 300 тыс. отзывов Wildberries, которые мы собрали сами, и на 300 тыс. отзывов Amazon для сравнения

Команда

Никита Червов · Светлана Жумлякова

Код и ноутбуки

github.com/ChervovNikita/hse_ai_course_work

Дисбаланс: пятёрок 76% на WB и 65% на Amazon

300 118

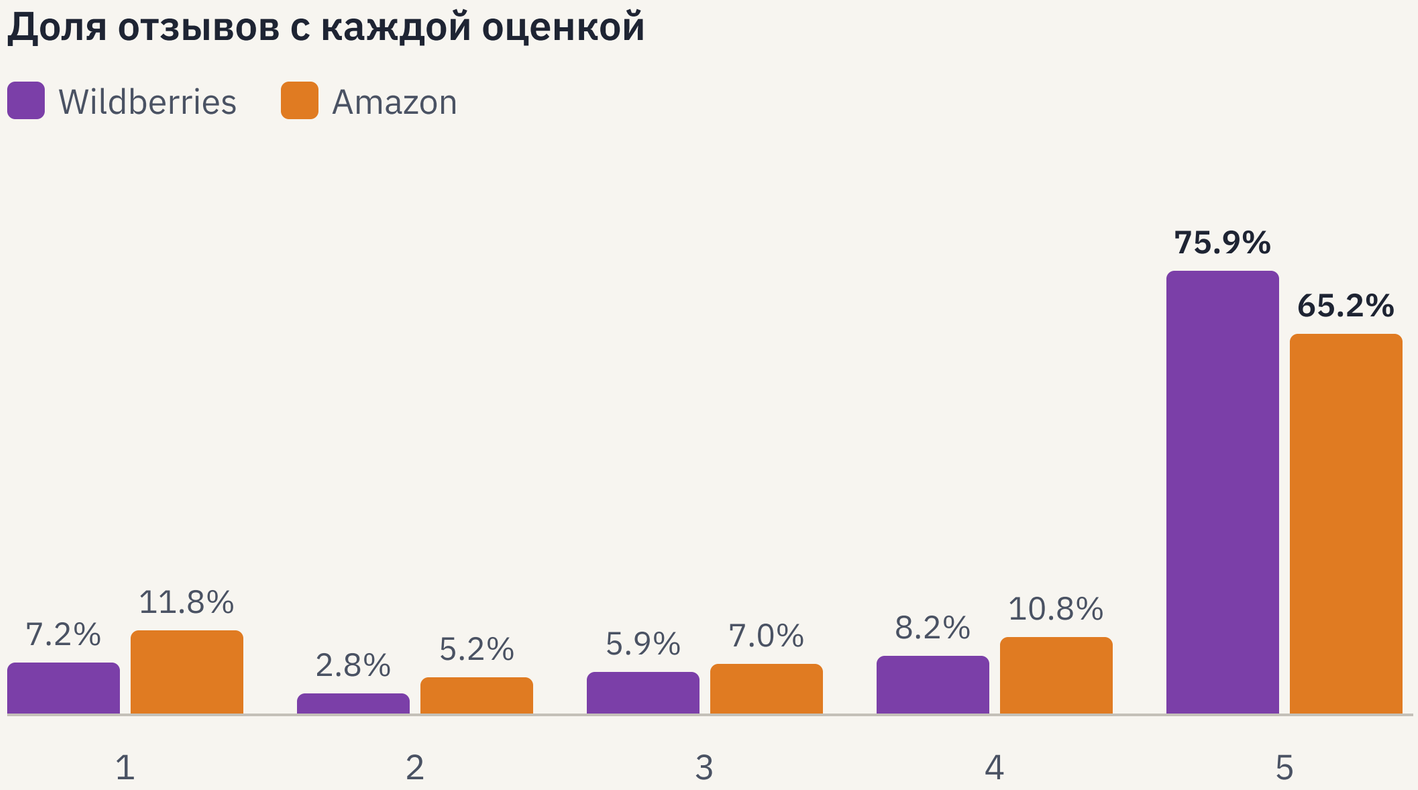
отзывов WB с оценкой 1–5, собраны нашим парсером

9 172

случайных товара из 93 категорий, не больше 100 отзывов на товар

300 034

отзыва Amazon для сравнения, та же логика выборки



Форма одинаковая: U-образная, самая редкая оценка 2. Метрики macro-F1 и MAE, обучение с весами классов

Качество данных: пропуски осмысленные, шум помечен

Пропуски — это поля формы

Основной текст пуст у 35% отзывов, но пустых отзывов нет: заполнены «Достоинства» или «Недостатки». Склеиваем три поля в один текст, строки не удаляем.

Скрытые пропуски

Размер «0» у 58% значит «без размера». Цвета нет у книг и продуктов. Без бренда средняя оценка ниже: 4.27 против 4.44, так что пропуск информативен.

Шум в разметке

WB сам помечает отзывы, где текст противоречит оценке: «Качество и красота» с оценкой 1. Такие 379 отзывов удалили, 2.7 тыс. отзывов о доставке пометили флагом.

Утечка метки в Amazon

У 10% отзывов Amazon подставил заголовок «Five Stars», который раскрывает оценку. Вырезали. Ещё 5.6% отзывов WB — шаблоны вроде «Все отлично».

Длина: отзывы короткие, пятёрки короче всех

Слов в отзыве	медиана	p95	p99	короче 3 слов
Wildberries	8	35	64	7.5%
Amazon	22	107	214	1.9%

Медиана по оценкам	1	2	3	4	5
Wildberries	10	11	11	11	**7**
Amazon	26	30	29	29	**19**

Длина отделяет только пятёрки: у оценок 1–4 медиана почти одинаковая.

«Пустые» отзывы («Отлично», «👍») почти все пятёрки: 8.8% у 5 против ~3.5% у 1–4.

Для моделей хватит 128 токенов на WB и ~384 на Amazon.

Частые биграммы по оценкам: темы общие для двух площадок

	1	2	3	4	5
WB	деньги на ветер ужасное качество	пункт выдачи после первой стирки	качество хорошее поэтому отказ	сняла звезду минус звезда	спасибо продавцу рекомендую к покупке
Amazon	waste money stopped working	poor quality didn’t work	runs small smaller than expected	good quality works great	highly recommend perfect fit

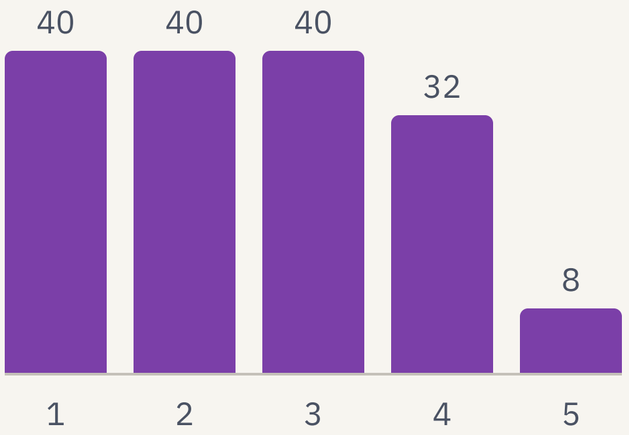
Крайние оценки различаются лексикой легко: «обман», «бракованный» против «находка», «восторге».

Средние оценки выдают «снижения» и мелкие претензии: «на троечку», «слабоват», «маломерит».

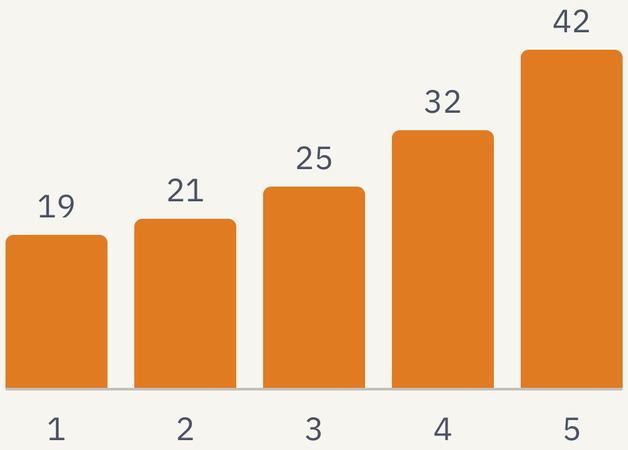
Темы претензий совпадают: размер, качество, «не как на фото». Различается только язык.

Признаки: главное в тексте, мета-признаки слабые

Заполнены «Недостатки», %



Заполнены «Достоинства», %



Корреляция Спирмена с оценкой

признак	ρ
есть «Недостатки»	−0.35
длина текста	−0.17
есть «Достоинства»	0.16
отзыв о доставке	−0.14
дизлайки отзыва	−0.11

Дрейф формы. До 2024 года полей «Достоинства» и «Недостатки» не было, поэтому признаки полей зависят от года.

Товар объясняет 13% дисперсии оценки, поэтому train и test делим по товарам.

Категория влияет: доля оценок 1–2 от 7.5% в одежде до 17% в товарах для сада.

Абляция и SHAP: биграммы и поля отзыва дают сигнал

Модель только для анализа: TF-IDF + LogReg с весами классов, split по товарам

Абляция на WB

Что на входе	macro-F1	MAE
A: только слова	0.428	0.460
B: + биграммы	0.450	0.392
C: B + has_pros / has_cons	**0.458**	**0.373**
D: B + метки полей в тексте	0.455	0.374

Доля |SHAP| по группам, %

оценка	1	2	3	4	5
слова	68	64	61	65	67
биграммы	27	30	**33**	**33**	20
флаги	6	6	6	3	12

Флаги — топ-1 и топ-2 по SHAP из 100 тыс. признаков. Заполненные «Недостатки» снижают логит пятёрки на ~1.0.

Биграммы важнее всего для 3–4: в топе отрицания «не очень», «не соответствует», «не рекомендую».

Честно про биграммы: они связаны со словами, поэтому смотрим долю по группам и абляцию.

Выводы и как используем их дальше

ЧТО УЗНАЛИ

- Дисбаланс одинаковый: 76% пятёрок на WB, 65% на Amazon
- Тексты короткие, «пустые» отзывы почти все пятёрки
- Биграммы и отрицания важны для оценок 2–4
- Поля «Достоинства» и «Недостатки» дают сигнал сверх текста
- Отзывы одного товара связаны между собой

ЧЕКПОЙНТ 3

- Полные датасеты с весами классов, macro-F1 и MAE
- Бейзлайн TF-IDF, затем fastText и BERT
- has_pros, has_cons и длина как признаки
- Разбиение train и test только по товарам
- Перенос моделей между WB и Amazon

Практическая ценность: кому это нужно

Маркетплейс

Находить отзывы, где текст противоречит оценке, и отделять жалобы на доставку от жалоб на товар. WB уже решает это сам.

Продавцы

Тысячи отзывов в день: модель поднимает негатив наверх, группирует претензии и оценивает тексты без звёзд.

Покупатели

Сводка «за что снижают оценку» вместо среднего рейтинга, который почти у всех 4.6–4.9.

Риски

Субъективные оценки и шум в разметке, дрейф интерфейса и сленга, неофициальный API площадки, заказные отзывы.

Как оценить качество

macro-F1 и MAE на новых товарах, полнота поиска негатива, доля пометок, подтверждённых модератором.