ГОДОВОЙ ПРОЕКТ · ЧЕКПОЙНТ 2 · EDA

Оценка товара по тексту отзыва

Многоклассовая классификация 1–5 на 300 тыс. отзывов Wildberries, которые мы собрали сами, и на 300 тыс. отзывов Amazon для сравнения

Команда

Никита Червов · Светлана Жумлякова

Код и ноутбуки

github.com/ChervovNikita/hse_ai_course_work

Данные: 300 тыс. отзывов и сильный перекос к пятёркам

300 118

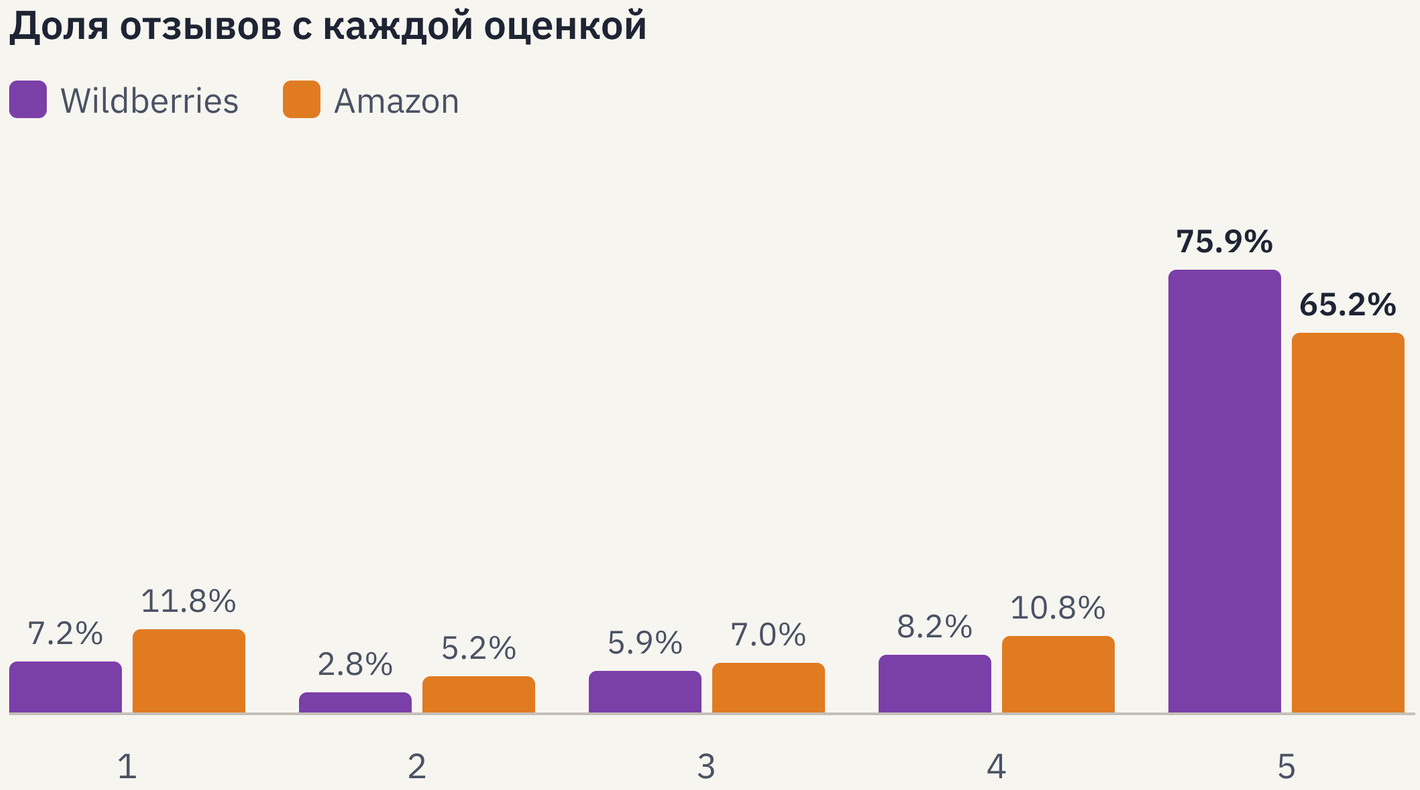
отзывов WB с оценкой 1–5, собраны нашим парсером

9 172

случайных товара из 93 категорий, не больше 100 отзывов на товар

8 слов

медианная длина отзыва (у Amazon 22)



Константа «всегда 5» даёт accuracy 0.76, поэтому метрики качества: macro-F1 и MAE

Качество данных: пропуски осмысленные, шум помечен

Пропуски — это поля формы

Основной текст пуст у 35% отзывов, но пустых отзывов нет: заполнены «Достоинства» или «Недостатки». Склеиваем три поля в один текст, строки не удаляем.

Скрытые пропуски

Размер «0» у 58% значит «без размера». Цвета нет у книг и продуктов. Без бренда средняя оценка ниже: 4.27 против 4.44, так что пропуск информативен.

Шум в разметке

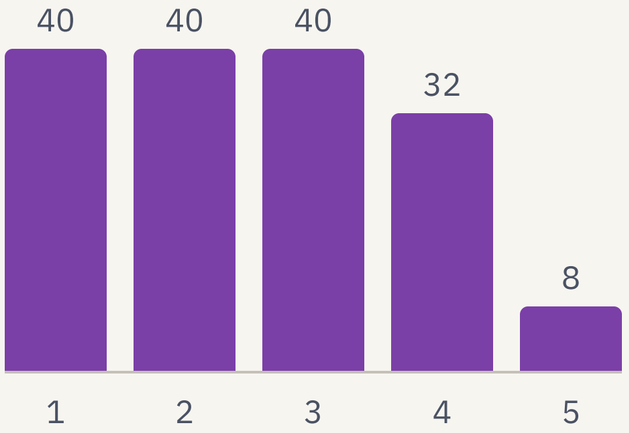
WB сам помечает отзывы, где текст противоречит оценке: «Качество и красота» с оценкой 1. Такие 379 отзывов удалили, 2.7 тыс. отзывов о доставке пометили флагом.

Утечка метки в Amazon

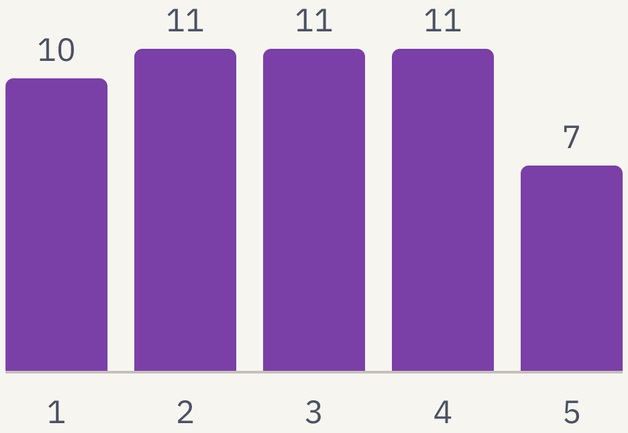
У 10% отзывов Amazon подставил заголовок «Five Stars», который раскрывает оценку. Вырезали. Ещё 5.6% отзывов WB — шаблоны вроде «Все отлично».

Признаки: главное в тексте, мета-признаки слабые

Заполнены «Недостатки», %



Медиана слов в отзыве



Корреляция Спирмена с оценкой

признак	ρ
есть «Недостатки»	−0.35
длина текста	−0.17
есть «Достоинства»	0.16
отзыв о доставке	−0.14
дизлайки отзыва	−0.11

Дрейф формы. До 2024 года полей «Достоинства» и «Недостатки» не было, поэтому признаки полей зависят от года.

Товар объясняет 13% дисперсии оценки, поэтому train и test делим по товарам.

Средние оценки выдают фразы «сняла звезду», «на троечку», «слабоват».

Бейзлайн: Amazon решается лучше, порядок методов тот же

macro-F1 · TF-IDF + логистическая регрессия · train и test разделены по товарам · жирным — лучший в столбце

Как обучали	WB, реальный тест	WB, сбаланс. тест	Amazon, реальный	Amazon, сбаланс.
константа «5»	0.172	0.067	0.157	0.064
полный датасет	0.443	0.362	0.505	0.439
полный + веса классов	**0.457**	0.467	**0.521**	0.528
balanced-датасет	0.432	**0.473**	0.509	**0.543**

Amazon проще: тексты в 3 раза длиннее, редких оценок в 2 раза больше.

Balanced-датасет выигрывает на сбалансированном тесте, хотя данных в 4–7 раз меньше.

Самая трудная оценка — 2: модель путает её с 1 и 3 на обеих площадках.

Выводы и как используем их дальше

ЧТО УЗНАЛИ

- Три четверти отзывов — пятёрки: accuracy бесполезна
- Сигнал почти весь в тексте, мета-признаки слабые
- Оценки 1 и 5 различаются легко, 2–4 похожи друг на друга
- Отзывы одного товара связаны между собой
- Форма отзыва на WB поменялась в 2024 году

ЧЕКПОЙНТ 3

- Метрики macro-F1 и MAE, веса классов
- Модели на эмбеддингах: fastText, ruBERT
- Ординальная постановка для оценок 2–4
- Разбиение train и test только по товарам
- Переобучение на свежих данных из-за дрейфа

Практическая ценность: кому это нужно

Маркетплейс

Находить отзывы, где текст противоречит оценке, и отделять жалобы на доставку от жалоб на товар. WB уже решает это сам.

Продавцы

Тысячи отзывов в день: модель поднимает негатив наверх, группирует претензии и оценивает тексты без звёзд.

Покупатели

Сводка «за что снижают оценку» вместо среднего рейтинга, который почти у всех 4.6–4.9.

Риски

Субъективные оценки и шум в разметке, дрейф интерфейса и сленга, неофициальный API площадки, заказные отзывы.

Как оценить качество

macro-F1 и MAE на новых товарах, полнота поиска негатива, доля пометок, подтверждённых модератором.